

“未央城”智能体大赛赛题文档

一、基础赛道：工科方向

1. 赛题背景

大语言模型面对结构严谨、推理链条复杂的工科基础课题目，存在推理不稳定、公式处理粗糙、解题步骤跳跃等问题。本赛道要求参赛者围绕清华理工科基础课程，基于赛事提供的基础模型优化一个解题 Agent，完成指定课程内的多种题型解答。

2. 课程与题目范围

2.1 指定课程

本赛道划定以下清华理工科基础课程作为解题范围：

- 基础物理学
- 电路原理
- 线性代数
- 微积分

上述课程对应清华大学本科教学体系中的相关课程内容，选手可结合课程教材、历年试题及课后习题进行训练集收集与 Agent 优化。

2.2 题目类型说明

两门课程均涉及多种题目形式，选手在 Agent 调优时需综合考量各类题型的处理能力。不同题目类型对 Agent 的能力要求差异显著。建议选手在构建训练集时优先保证数值计算题与推导题的覆盖密度，同时适当纳入含图题以提升 Agent 的多模态综合处理能力。

最终评分将综合考量训练集题目的难度分布与 Agent 的解题准确率，具体量化评分比例将在后续补充说明中给出。

3. 数据集说明

3.1 训练集

3.1.1 收集方式

训练集由参赛队伍自主收集，主办方不统一提供训练数据。选手可从以下正规渠道收集题目与答案数据：

- 课程配套教材中的习题及解答

- 课程参考样题答案（可向任课教师或助教申请获取）
- 课程官方习题册或讲义中的例题
- 各类正规出版物或学术平台上的公开例题（需确保来源合法合规）

3.1.2 数据格式

选手按照给出的示例格式组织数据。示例 JSON 格式如下：

```
{
  "question_id": "PHY_001",
  "type": "数值计算",
  "difficulty": "中等",
  "question": "一质量为 2kg 的物体在水平面上做匀变速直线运动，初速度为 4m/s，加速度为 -1m/s2，求 6s 末物体的速度。",
  "answer": "v=v0 +at=4+(-1)×6=-2m/s，即反向运动，取|-2|=2m/s",
},
{
  "question_id": "CIR_001",
  "type": "数值计算",
  "difficulty": "基础",
  "question": "如图所示，R1=10Ω，R2=20Ω，R1 与 R2 并联后接 30V 电源，求总电流。",
  "answer": "I=U/Req，1/Req=1/10+1/20=3/20，Req≈6.67Ω，I=30/6.67≈4.5A",
}
```

3.2 测试集

测试集由主办方统一生成，涵盖指定课程的多种题型与难度层次，具体内容在正式评测前对参赛者保密。Agent 的输出应当按照以下示例格式：

```
{
  "question_id": "PHY_001",
  #保证与前面的问题 id 严格对应
  "reasoning_process": "(具体解题过程，用于评分步骤评审)",
  "answer": "v=v0 +at=4+(-1)×6=-2m/s，即反向运动，取|-2|=2m/s",
},
{
  "question_id": "CIR_001",
  "reasoning_process": "(具体解题过程，用于评分步骤评审)",
  "answer": "I=U/Req , 1/Req=1/10+1/20=3/20 , Req ≈ 6.67 Ω ,
I=30/6.67≈4.5A",
}
```

比赛结束前一周，主办方将为参赛团队提供验证集（与最终测试集题型、难度相仿），帮助选手理解赛事最终测评格式规范及赛事题型、分数划分。

3.3 评测流程

主办方将在统一的测试环境中对各队伍提交的 Agent 进行部署，通过测试用例进行可视化演示挑战。评测过程中，Agent 须在测试环境内独立完成解题，全程不接受人工干预。

4. Agent 构建说明

4.1 基础模型

主办方将向各参赛队伍提供 Kimi: K2.5 模型 API，选手应当基于给定的基础模型进行 Agent 开发与调试。

4.2 Baseline 与 Demo

主办方将随赛题说明文档同步提供以下资源：

- 赛题 Baseline
- 参考示例：若干涵盖典型题型的完整输入输出演示

选手应在 Baseline 基础上，结合助教团队的辅导进行完善与优化，不得直接以未经改动的 Baseline 作为最终提交版本。

4.3 选手提交内容（重要）

选手必须提交的内容包括：

- 源代码文件
- requirements.txt（写明所有依赖的 python 包）
- submission.json（写明需要实例化的智能体类(Class)和需要调用的解题方法(Method））

注意：选手最终实现形式应为“库”而非简单脚本文件。选手应当在主程序代码中实现需要赛题方实例化的类和需要赛题方调用的方法，并将相关信息填在 submission.json 文档中。

5. 评分说明

具体评分细则见下图及对应网页地址。评分公示时将同时展示选手作品生成答案及对应得分细则，选手可在公示网页查询。

智能体大赛评分框架 点击各维度查看细则



验证集正确率（40 分）

×1.0

基础题全对

答案精确匹配或等价，数值、单位均正确

×1.5

中等题全对

多步推导、需调用多个工具协作完成

×2.5

困难题全对

综合分析、跨科推导，仅凭底模难以直接回答

答案有误时按步骤与公式给分（仅限计算题）

情形

公式 + 步骤均正确

公式正确，步骤不完整

公式错误，方向正确

方向错误或无过程

得分比例

× 70%

× 40%

× 20%

× 0%

判定说明

建立了正确的物理模型，套用了正确公式，步骤完整，仅因代入数值或简化简出错导致最终数值错误

选用了正确公式，但推导步骤缺失或跳步，无法完整还原解题过程

分析思路方向正确（如正确识别了物理量关系），但选用公式有误，导致数值完全错误

物理模型建立错误，或直接输出错误答案而无任何推导过程

填空题不适用步骤给分，答案完全正确得满分，否则得 0 分。步骤给分后再乘以对应难度系数（×1.0 / ×1.5 / ×2.5）。

每题时间限制

填空题

1 分钟 / 题

答案简短、无需复杂推导。超时视为本题未作答，正确率与过程分均清零。

计算题

3 分钟 / 题

含多步符号推导或数值计算，允许多次工具调用。超时视为本题未作答，正确率与过程分均清零。

超时处理规则：超出时限后系统强制中断，本题得 0 分（含正确率 + 过程分）。效率子项“平均响应时间”按实际用时 / 对应时限计算达标率，填空题和计算题分开统计后加权平均。

验证集难度加权方案（内含于正确率维度）

基础题

中等题

困难题

占 40%，×1.0 概念定义、单步计

占 40%，×1.5 多步推导、多概念

占 20%，×2.5 综合分析、证明、

科

总分（标准化后）

100 分

设计原则：底模统一（K2.5），选手差距体现在知识工程与工具设计上，过程质量 + 方案设计合计 45 分，占比超过正确率。数值有误但步骤公式正确可按比例得部分分，体现对推导过程的尊重。时限按题型分级（填空 1 min / 计算 3 min），超时强制清零。

具体评分细则（每一类题目都有对应的细则类比）请选手前往云盘链接，下载网页查看详情。

链接：<https://cloud.tsinghua.edu.cn/f/c14b1a429f6e41c59341/?dl=1>

6. 优秀作品去向

本赛道表现优异的 Agent 作品，将有机会以课程改革项目形式被接入基础物理学、电路原理等相关课程，为全校本科生提供智能解题辅助服务。

二、创意赛道

1. 赛题背景

在书院日常的教学管理与学生服务中，存在大量高度依赖人工处理、流程规则复杂且重复性强的行政与学术事务。尽管“未小羊”等初步智能工具已投入使用，但在面对政策条文的深度解读、复杂表单的自动化填充以及跨部门流程的逻辑引导时，仍存在理解不准确、响应不及时的限制性。

本赛道鼓励参赛者利用大语言模型在自然语言理解与逻辑编排上的优势，构建具备自主行动能力的智能体。选手需深入调研书院真实的办公与学习场景，针对行政老师反馈的高频痛点及学生在科研报销、奖助学金申请等环节的实际困难，开发出能够精准识别意图、自动调度工具并生成合规成果的智能解决方案。

2. 灵感参考

本赛道不设固定赛题，选手可从以下参考方向中任选其一，或自行挖掘校园内的真实痛点进行创作。

1) “未小羊”行政效能进阶

任务目标：针对“未小羊”智能体的若干个高频行政场景（如学籍管理、奖助学金政策解读、办事流程导引等）进行专项逻辑增强。

主办方提供：书院老师已整理出了部分亟待解决的问题（请见<https://cloud.tsinghua.edu.cn/f/03366d3e6aaf4dee970f/>），主办方将提供相关的学生手册、行政通知等公开文档模板。

制作思路：利用 RAG（检索增强生成）技术构建精准知识库，并设计多轮对话逻辑，使 Agent 能够根据用户身份（如年级、专业）给出定制化的办事建议。

2) 物理实验报告智能辅助

任务目标：开发一个能够辅助学生进行物理实验数据预处理、量纲校验，并辅助生成规范化报告初稿的智能助手。

主办方提供：物理实验报告的空白模板及实验记录样表格式。

制作思路：构建具备逻辑校验能力的 Agent，使其能识别数据中关键信息，并根据选手的模拟实验数据，自动填充模板中的背景、原理及误差分析框架。

3) 奖学金/资助申请顾问

任务目标：协助学生从复杂的个人事迹中提炼符合申请要求的亮点，并实现申请材料的自动化排版。

主办方提供：奖学金申请表、荣誉证书等去敏感化后的标准空白文件格式。

制作思路：设计对话式意图识别，引导学生输入个人成果，Agent 自动将信息分类并填充至空白模板对应的字段中，确保格式符合书院要求。

4) 财务报销与预决算助手

任务目标：针对社团或科研项目的财务报销痛点，实现预算表与决算表的逻辑核对，并辅助整理合规材料。

主办方提供：标准的预算表、决算表空白 Excel/Word 格式模板。

制作思路：利用 Agent 的代码执行或逻辑比对能力，自动核验消费条目与预算类目的一致性，并针对不合规项给出修改建议。

3. 技术路线

为帮助参赛队伍快速从创意走向落地，可参考以下技术路线与开发平台。

1) 扣子 (Coze.com) / 智谱 (Z.ai)

Coze 提供了开箱即用的工作流 (Workflow)、插件扩展及持久化记忆化能力，能够通过拖拽式界面快速集成大模型 API。

智谱 BigModel 开放平台：可对模型进行更深层定制、精细化控制模型调用参数或进行微调。

2) 构建思路

检索增强生成 (RAG)：针对“行政政策解读”或“实验报告辅助”等依赖特定知识库的场景，可构建数据库。通过将手册、文档等素材存入知识库，使 Agent 能够检索到准确的上下文信息，解决模型“幻觉”问题。

工作流与插件调用：在处理“财务报销”或“自动填表”等任务时，设计工作流。利用 Agent 的工具调用能力，触发特定的计算函数或格式化脚本。

多轮对话管理与记忆：为了解决实际行政工作中的难题，Agent 需要具备良好的长短期记忆管理能力，能够联系上下文理解用户的真实意图，并在信息不全时主动进行反问引导。

3) 合成数据

在创意赛道中，选手需利用基础模型（如智谱 API）基于空白模板批量生成模拟数据。构建高质量的指令微调数据集，以提升 Agent 在特定表单填充任务上的准确度。

4. 评分标准

1) 技术基础分 (20%)

评审方式：赛前测试/后台验收

逻辑严密性：Agent 工作流、检索及插件调用逻辑科学合理。

运行稳定性：基础用例响应迅速、格式正确，对若干场景回答准确。

技术运用：大模型 API 整合效率高，无重大技术漏洞。

2) 创意答辩分 (80%)

评审方式：决赛现场专家（含书院领导、行政老师、技术专家）打分

需求真实性：是否解决了书院行政或学生生活的实际痛点。

方案独创性：产品形态与交互逻辑是否具有创新思维。

落地可行性：是否具备集成至“未小羊 2.0”并投入校园使用的潜力。